

DUOCUC · SCY1101 · JUNIO 2026

Análisis Predictivo y Dashboard Interactivo · Google Play Store

Ignacio Sobarzo · Francisca Miranda · Diego Yañez

github.com/Ignacio/Ciencia-_de_datos_google_playstore

Agenda

01

Problema de Negocio

03

Por qué elegimos los modelos

05

Segmentación K-Means

07

Organización y metodología ágil

09

Hallazgos Clave

02

Pipeline ETL

04

Optimización

06

Dashboard y audiencias

08

Herramientas de colaboración

10

Conclusiones y mejoras

¿Qué factores determinan la popularidad de una app?

9.438

Apps analizadas
Del dataset de Google Play Store


20,8%

Apps populares
Alcanzan o superan 1.000.000 de instalaciones

4,19

Rating promedio
Sobre 5,0 puntos

Flujo End-to-End



Cada etapa asegura datos limpios, equilibrados y listos para el modelamiento predictivo.

¿Por qué elegimos Random Forest?

Modelos evaluados

- **Regresión Logística** — baseline lineal
- **Decision Tree** — interpretable
- **SVM** — margen de separación
- **Random Forest** — **modelo seleccionado**

Random Forest captura relaciones no lineales, es robusto a outliers y entrega Feature Importance nativa.

Resultados del modelo

- Accuracy: **0,9534**
- F1-Score: **0,8869**
- ROC-AUC: **0,9890**

División 80% entrenamiento / 20% prueba. Comparación y curva ROC disponibles en el dashboard.

Optimización y Segmentación No Supervisada

Optimización de hiper parámetros

Después optimizamos los hiper parámetros. Para Random Forest usamos GridSearchCV que prueba todas las combinaciones posibles.

- `n_estimators = 200`
- `max_depth= none`
- Validación K-Fold = 5

Segmentación K-Means

- **k = 3** clusters, seleccionado por Método del Codo
- PCA: 2 componentes principales
- Varianza explicada: **47,2%**

Dashboard Interactivo en Plotly Dash


Vista Ejecutiva

- Análisis Exploratorio
- Resumen del Dataset
- KPIs de negocio y tendencias de mercado
- Distribución FREE vs PAID (92,7% vs 7,3%)

Vista Técnica

- Preparación de Datos
- Resultados del Modelo
- Análisis de Clusters
- Métricas detalladas, matrices de confusión y PCA interactivo

TOP 10 CATEGORÍAS POR INSTALACIONES



GRATIS VS PAGO



CLASIFICACIÓN DE CONTENIDO




KPIS DEL DATASET



DISTRIBUCIÓN DEL DATASET



Apps Gratuitas vs De Pago



Valores nulos por columna (dataset original)



VISTA PREVIA DEL DATASET LIMPIO

Vista previa del dataset limpio (primeras 6 filas)


App	Category	Rating	Reviews	Size_MB	Type	Installs	popular
Instagram	SOCIAL	4.5	66577446	7.9	FREE	1000000000	1
Subway Surfers	GAME	4.5	27725352	76.0	FREE	1000000000	1
Google Photos	PHOTOGRAFIA	4.5	10859051	9.65	FREE	1000000000	1
WhatsApp Messenger	COMUNICACION	4.4	69119316	5.7	FREE	1000000000	1
Google	TOOLS	4.4	8033493	4.2	FREE	1000000000	1
Google Drive	PRODUCTIVIDAD	4.4	2731211	6.9	FREE	1000000000	1

TRANSFORMACIÓN LOGARÍTMICA EN REVIEWS

Selecciona la vista:

☐ Distribución original (sesgada) ☒ Log-transformada (simétrica)


log(Reviews + 1) — distribución transformada (simétrica)




ACCURACY	F1-SCORE	PRECISIÓN	RECALL	ROC-AUC
0.9534	0.8869	0.8961	0.8779	0.9890

COMPARACIÓN DE MODELOS Y CURVA ROC

Comparación de ROC-AUC — 4 Modelos



Curva ROC — Random Forest Optimizado



MATRICES DE CONFUSIÓN — LOS 4 MODELOS

Matrices de Confusión — 4 Modelos




OPTIMIZACIÓN DE HIPERPARÁMETROS — GRIDSEARCHCV

GridSearchCV — F1 promedio por hiperparámetros (min_samples_split=2)



Método del Codo — Elección de k




VISUALIZACIÓN PCA — CLUSTERS VS POPULARIDAD

Colorear por:

☐ Cluster (K-Means) ☒ Popularidad real

PCA coloreado por Popularidad real — varianza explicada: 47.2%



Organización del Equipo con Kanban

Semana 1

Configuración del repositorio, limpieza de datos y modelamiento supervisado y no supervisado.

1

2

Semana 2

Desarrollo del dashboard, adaptación a audiencias y preparación de la presentación final.

Herramientas de Colaboración

- Para esta nueva evaluación utilizamos nuevas herramientas las cuales antes no utilizabamos, las cuales nos ayudaron a tener una mayor productividad y mejor registro.

GitHub

Se utiliza Github para guardar el notebook, modelo, base de dato limpia y el dashboard interactivo.

Issues

README completo en repositorio público junto a los requerimientos.

Miro

Arquitectura visual y planificación del pipeline ETL end-to-end.

Kanban

Control de estados, prioridades y responsables en tiempo real.

Hallazgos Clave y Conclusiones

Hallazgos principales

- El rating solo no explica la popularidad
- Reviews, Size y Type son determinantes
- Las transformaciones logarítmicas son esenciales para variables con alta dispersión

Mejoras futuras

- Más filtros interactivos en el dashboard
- Actualizar el dataset con información reciente
- Crear un modelo en paralelo para apps antes de ser publicadas